

Panduan Pengisian Database

Di dalam suatu database atau cluster terdapat kumpulan koleksi, satu koleksi mewakili satu jenis data. Jenis data: publikasi, tabel, brs, general, dan seterusnya. Contoh di bawah adalah untuk data general (informasi umum BPS).

1. Gambaran Umum

Alur kerja pengisian database terdiri dari **4 tahap utama**:

Tahap	Tujuan	Script Utama	Input	Output
1	Membagi teks mentah menjadi potongan kecil (chunk)	chunking_general.py	general.json	general_chunked.json
2	Mengubah setiap chunk menjadi vektor embedding	embed_general.py	general_chunked.json	general_embed.json
3	Membuat koleksi di Zilliz (struktur database vector)	create_collection (zilliz vector db).py	—	Koleksi bernama "general" di Zilliz
4	Memasukkan data hasil embedding ke dalam Zilliz	load_collection (zilliz vector db).py	general_embed.json	Data tersimpan di Vector DB

2. Persiapan Awal

Daftar File

- general.json
- general_chunked.json
- general_embed.json

|— create_collection (zilliz vector db).py

|— load_collection (zilliz vector db).py

|— embed_general.py

|— chunking_general.py

Kebutuhan Python

Pastikan paket berikut terpasang:

pip install langchain-text-splitters tiktoken sentence-transformers pymilvus torch

3. Tahap 1 — Membuat Chunk

File: chunking_general.py

Script ini membagi teks panjang dalam general.json menjadi potongan-potongan kecil dengan konteks lengkap.

Jalankan

python chunking_general.py

Hasil

File output:

general_chunked.json

Format contoh hasilnya:

```
[
  {
    "chunk_id": "informasi-umum-bps_0",
    "page_content": "Menu: Profil BPS. Title: Informasi Umum BPS. Part 1/8: Badan Pusat Statistik ...",
    "metadata": {
      "service_id": "informasi-umum-bps",
      "title": "Informasi Umum BPS",
      "menu": "Profil BPS",
      "link": "https://ppid.bps.go.id/app/konten/3273/Profil-BPS.html"
    }
  }
]
```

4. Tahap 2 — Membuat Embedding

File: `embed_general.py`

Script ini:

- Memuat model **google/embeddinggemma-300m**
- Mengubah setiap chunk menjadi vektor 768 dimensi
- Menyimpan hasil embedding ke JSON baru

Jalankan (di Colab atau lokal GPU)

```
python "embed_general.py"
```

Hasil

File output:

`general_embed.json`

Contoh hasil:

```
{
  "chunk_id": "informasi-umum-bps_0",
  "page_content": "Menu: Profil BPS. Title: Informasi Umum
BPS. Part 1/8: Badan Pusat Statistik ...",
  "embedding": [-0.0847646, 0.12533, ...],
  "metadata": { ... }
}
```

5. Tahap 3 — Membuat Koleksi di Zilliz

File: `create_collection (zilliz vector db).py`

Script ini membuat **koleksi (collection)** bernama "general" di Zilliz Cloud dengan struktur field seperti:

- unique (Primary key)
- embedding (FLOAT_VECTOR)
- page_content, title, link, dst.

Langkah-langkah:

1. Ubah kredensial koneksi:
2. ZILLIZ_ENDPOINT = "https://YOUR-ZILLIZ-ENDPOINT"
3. ZILLIZ_TOKEN = "YOUR-ZILLIZ-API-TOKEN"
4. Jalankan script:
5. python "create_collection (zilliz vector db).py"

Jika sukses, akan muncul:

Successfully created and loaded collection 'general' with a vector index.

6. Tahap 4 — Memasukkan Data ke Zilliz

File: load_collection (zilliz vector db).py

Script ini:

- Membaca file hasil embedding (general_embed.json)
- Menyisipkan data ke dalam koleksi general
- Melakukan batch insert dan flush

Langkah:

1. Ubah nama file input agar sesuai:
 2. input_filepath = Path(r"C:\qwe\database\general_embed.json")
 3. Pastikan endpoint dan token sama seperti di tahap 3.
 4. Jalankan: python "load_collection (zilliz vector db).py"
-

7. Verifikasi di Zilliz Cloud

1. Login ke Zilliz Cloud Console.
2. Pilih collection "general".
3. Pastikan field dan jumlah data sesuai.

Default Project

Clusters

API Playground

Management

Backups

Migrations

Jobs

Collaborators

Project Alerts

Docs | Support

+ Cluster

Free-01

- tables
- press
- publications
- news
- general

OverviewDataAPI PlaygroundVector SearchIndexesPartitionsActions

Data

QueryImport DataInsert Data

chunk_id	embedding	page_content	Action
alamat-dan-kontak-bps_0	[-0.08559001,0.023148386,0.0...	Menu: Profil BPS. Title: Alamat ...	Q
arti-logo-bps_0	[-0.078458264,-0.002373071,0...	Menu: Profil BPS. Title: Arti Log...	Q
arti-logo-bps_1	[-0.08614267,0.0033761503,-0...	Menu: Profil BPS. Title: Arti Log...	Q
booklet-atau-leaflet-layanan_0	[-0.046381548,-0.0001342511...	Menu: Layanan BPS. Title: Boo...	Q
booklet-atau-leaflet-layanan_1	[-0.04746418,0.025591325,0.0...	Menu: Layanan BPS. Title: Boo...	Q
booklet-atau-leaflet-layanan_2	[-0.037314124,0.020441046,0...	Menu: Layanan BPS. Title: Boo...	Q